

Operating System

Abstraktionsebene zwischen Hard- und Software

Modular vs Monolith

Modular: + kleiner Kernel - complexity (IPC)

Monolithic: + consistency - Bloatware (unnecessary stuff)

Aufgaben

Ressourcenmanagement CPU/RAM/Disks / IO

Hardware Abstraktion → I/O devices

Bootung

1. BIOS durchläuft POST (Power On Self Test)
2. Master Boot Record wird eingelesen & ausgeführt
3. MBR wählt einen Bootloader (GRUB) aus und lädt ihn
 - a. OS wird gestartet, lädt Treiber aller Geräte
 - b. Initialisiert OS Management Strukturen
 - c. (creates system services (sys calls, etc.))
 - d. Spawns a (User) interface (GUI)

Bootung in Linux

1. System Startup / HW Initialization
2. MBR wird eingelesen und ausgeführt
3. Kernel (Linux OS): OS start-up code
4. INIT process (run kernel)
5. User prompt (Shell or GUI)

BIOS vs. UEFI

UEFI ist im Gegensatz zum BIOS ein eigenes kleines OS. BIOS braucht den MBR und UEFI eine Partition. MBR wird mit GPT ersetzt für UEFI.

UEFI nutzt eine Architektur unabhängige VM, dadurch kann sich EFI binaries ausführen unabhängig von Partitionen

UEFI → EFI Bootloader → Kernel

ID	Name	Description
0	halt	Shuts down the system
1	Single user-mode	Admin tasks
2	Multi user-mode	
3	" with networking	starts the system normally
4	Not user-mode-definable	special purposes
5	next system normally with appropriate GUI	runlevel 3 + GUI
6	Reboot	

RANDISK

HW needed to load Kernel is stored on that disk itself.

initrd stored in same area as kernel. Contains kernel + basic device-special files.

systemd

system & service manager for Linux. Provides dep-system between units. Unit (object) **states**: (in)active, (de)activating, failed. Unit **types**: service (OS service), target (like runlevel). Targets don't offer additional functionality → group units. default config: /etc/systemd/systemd.conf

Unit files: /lib/systemd/system → etc/systemd/system

Processes

run in user-mode → may trap into kernel-mode (system calls). 0 associated owner, reside within an EUID.

Creation: Boot, User request, fork(), exec(), library, cron jobs

Termination: Voluntary, error, murder (killed)



Context vs. Mode Switch

- Mode switch: no sched involved (e.g. ISR)
- Mode/context switch: sched involved

Threads

Per process items: Address space, global variables, open files, child process

Per thread items: stack, PC, registers, state

→ created & owned by a process. Linux Thread is a process that shares a configurable set of resources with other processes.

Kernel thread: runs exclusively in system mode.

Kernel vs. Linux Thread

Kernel: ① kernel kann Threads → gut für viele I/O calls, blocking (un-interruptible) ② Threadwechsel = 2 Kontextwechsel

Thread: ① effizienter, cheaper ② IO = blocking process

Orphan vs. Zombie

Zombie: state until child sends exit state to parent and he acks it. Orphan: Parent terminated without waiting for children.

Scheduling

sorts a queue according to some policy.

→ dispatcher moves the task from head to CPU (⇒ context switch)

- FIFO / FCFS → simple, non-preemptive

Round Robin

- One queue with time-slicing (slice = quantum)
- pre-emptive, no starvation, simple

1. running task interrupted every slice (arriving has prio)
2. if queue not empty, task adjourned to end of queue
3. task at head of queue gets dispatched

Heuristics

allows user to influence task priorities

Rate Monotonic

→ highest prio given to task with highest repetition rate. guaranteed schedule if: $U = \sum_{i=1}^n \frac{C_i}{T_i} \leq \frac{n(2^n - 1)}{\ln(2)} \approx 0.6931$

$U \leq 1 \Rightarrow$ Sched possible; $U > \ln(2) \Rightarrow$ nicht garantiert

Linux Scheduler = Completely Fair Scheduler

gibt jedem Task die gleiche CPU Zeit. nice: [-20,19] → higher value = lower prio

Optimales Scheduling

CPU soll so ausgelastet sein, dass die Jobs in der kürzesten Zeit fertig sind.

Starvation: Prozess/Thread ist ready, bekommt aber keine CPU Zeit

(Non)preemptive Scheduling

In preemptive scheduling wird die CPU einem Prozess für eine limitierte Zeit zur Verfügung gestellt, während in Non-preemptive ein Prozess die CPU hat bis er fertig/waiting ist.

Realtime vs. preemptive Scheduling

Realtime → Prozesse haben eine gewisse Zeit, in der sie ausgeführt werden müssen. Preemptive → CPU kann Prozesse unterbrechen und gibt Prozesse nur eine geringe CPU time.

cgroup-ps

Teil des Linux Kernel, mit dem sich die Nutzung von Ressourcen durch Prozesse beschränken & überwachen lässt. → "a cgroup is a collection of processes that are bound to a set of limits or parameters defined via the group filesystem" → Bsp.: CPU, memory

V1 vs. V2

V1: Each V1 controller may be mounted against a separate cgroup filesystem. Also possible to co-mount (multiple controllers against same cgroup). Controllers require at least one cgroup filesystem, can only be mounted to one at the same time. Each cgroup is represented by a directory. Task cannot be a member of two different cgroups in the same hierarchy.

V2: All mounted controllers reside in a single unified hierarchy.

Operations

Creation: eine neue cgroup wird erstellt, indem man einen Ordner unter einem entsprechenden Controller erstellt. mkdir /sys/fs/cgroup/cpu/new_group

Löschen: cgroup darf keine child cgroups haben & cgroup darf keine non-zombie Prozesse beinhalten. → rm -rf ...

Memory

Swapping

Datentransfer zwischen RAM & Festplatte. Festplatte wird als temp storage für Prozesse verwendet, wenn der RAM voll ist. Lange nicht mehr genutzte Daten werden temporär auf die HDD geschrieben. → Multitasking ist möglich dank swapping.

Placement Algorithms

- Zuordnung von Prozessen im bestehenden Memory
- 1. First fit: first fragment that fits
- 2. Best fit: Zuordnung zum Fragment, das von der Größe am besten passt → viele kleine ungenutzte Fragmente
- 3. Next fit: erstes Fragment ausfinden von letzten Zugriff
- 4. Buddy: teilt memory 1/2 bis best fit erreicht ist. Freie memory Blöcke werden wieder zu größeren Blöcken gerundet.

Virtual Memory

Speicheranforderung von Prozessen übersteigt den physischen vorhandenen Speicher. OS gewährt Prozessen vorübergehend Memory zur Verfügung zu haben. → Prozesse werden auf der Harddisk gespeichert. Falls der Prozess aktiv ist, wird er ins Memory geladen.

Page Table: Daten sind im Memory verteilt oder auf die Festplatte ausgelagert (paged out). Die page table mappt bei einer Speicherabfrage einer Prozesses die virtuellen Adressen auf physische Adressen.

Page (virtual mem block) → Frame (physical mem block)

Memory Management Unit - MMU

- MMU schaut, dass Prozesse nur auf Memory zugreift, welcher ihnen zugeteilt wurde

- Adress Translation: virtuelle Adresse → physische Addr.
1. TLB hit or page table (low pages)

Virtual address (page #, offset) → returns (frame #, offset)

Translation Lookaside Buffer - TLB

cached die letzten 64 Page Table Zugriffe. MMU schaut bei Zugriffen immer zuerst, ob die Entries im Cache sind.

Falls nicht → check page table.

Page Replacement

→ wenn der physische Speicher im RAM überläuft.

1. **FIFO:** ersetzt die älteste Page in der Queue

2. **Optimal:** ersetzt page, welche in Zukunft am wenigsten häufig gebraucht wird. → nicht umsetzbar

3. **LRU:** ersetzt page, welche am längsten nicht gebraucht wurde

Page fault

→ Wenn ein Prozess auf eine Speicheradresse zugreift, welche momentan nicht ins Memory gemapped ist.

Input / Output

Device categories

Block: blocks with fixed size. → Harddisk

Character: operates on char streams

I/O architecture

Southbridge: all I/O devices, PCI Bus, Flash rom (slow devices)

Northbridge: PCI express, CPU, memory bus (fast devices)

x86 architecture: map peripheral I/O registers to system address range and buffer into memory

Direct Memory Access - DMA

CPU kommuniziert mit dem Speicher über einen Bus mit hoher Bandbreite. → DMA controller bearbeitet I/O requests, damit die CPU weiterarbeiten kann

Access

Continuos: Polling, sync

Event-based: interrupts, async

Blocking: request → wait → receive

Non-blocking: request → receive

Buffered I/O: decoupler data access from generation

Custom Kernel

① tiny kernel → load only what is needed

- support for HW that is hot-pluggable

File Systems

a file is an abstraction, a logical unit of information created by a process.

File Types

Dirs, regular files, char special files (serial I/O devices), block special devices (disks)

Links

Hardlink: dir entry that maps a name with the inode of an existing file → cannot be created for dirs

Symbolic: file that points to a file/dir but doesn't mirror the other's file data → different i-node

Trypts

file system that stores files in RAM. → use for fast access to non-critical data

Logical Volume Management - LVM

Copy on Write: Optimierungsmethode zur Vermeidung unnötiger Kopien. Kopie wird erst dann erstellt, wenn file beschrieben wird.

Snapshot: read-only, copy of the file system state

B-tree file system / RAID

Disks sind unerlässlich → mit mehreren Disks einen zuverlässigen Speicher realisieren

RAID 0: Daten auf 2 HD splitten und in beiden zur die Hälfte reinschreiben → 2x schneller - Datenverlust

RAID 1: Daten auf 2 HD gespiegelt schreiben → + Datensicherheit - Effizienz

RAID 10: RAID 0, aber man spiegelt jede Hälfte auf 2 HDDs wie in RAID 1

→ + 2x schneller, Ausfallsicherheit für 2 HDD, - teuer

Networking (0-7: Kernel; 8-9: User)

Requirements: Local IPC, Protect machine from malicious traffic, Route traffic to different network interfaces

L1: connect physical network interface card to rest of the system via system-bus (kernel-space)

L2: Frame from network interface → memory, Bridging

L3: firewall, routing → IP packet entry checks

L7: API to tap into OS networking stack (Berkeley)

Linux Commands

System info

kernel version: `uname -a` cores: `lscpu`

memory: `free -k` manufacturer feat.: `lshw`

PCI devices: `lspci` (-k for kernel drivers)

USB devices: `lsusb` I/O stats: `iostat (-dev /dev...)`

or `iostat`

Booting

available target units: `systemctl list-units` → type target

default target: `systemctl get-default`

default target unit file: `cat /etc/systemd/system/default.target`

recursively list deps: `systemctl list-dependencies default.target`

service status: `systemctl status ...service` or `journalctl -u ...`

see unit file: `systemctl cat sub.service` → requires: unit this depends on, started when this unit is started

wants: weaker than "requires" → listed units are started, even unit not stopped if any of them fail; immediately enable

start service: `sudo systemctl enable --now my.service.service`

Processes (PID 0 = child, -1 = error, else parent)

current PID: `pidof tail` process hierarchy: `ps tree -p PID`

running process: `ps auxf -eo pid,ppid,cmd,psr` monitor syslog:

tail -f /var/log/syslog process to PID: `ps PID` kernel threads: `ps -eo ppid,`

`ppid,cmd,stat` | `grep [k]worker`

Scheduling

change prio: `nice -n [value]` (percentage change niceness of running

process: `renice -n [value] -p [PID]` scheduler of a process: `cat -p PID`

cgroups

display cgroup info: `ls /sys/fs/cgroup` hierarchy: `system - cgroup`

create CPU 2 & 3: `sudo cgroup -d 2-3` create cgroup: `mkdir /sys/fs/cgroup/cpu/newgroup`

`fs/cgroup/cpu/newgroup` add process to cgroup: `PID > /cgroup/process`

limit process memory: `echo 2M > /sys/fs/cgroup/memory/memory.limit_in_bytes`

mounting: `mkdir /cgroup/cpu → mount -t tmpfs -o size=2M tmpfs /cgroup/cpu`

→ `mount -t cgroup -o cpu none /cgroup/cpu`

Files

`ls -al ...` → (owner/group/permissions), Link, Owner/Group, size, ...

permissions: `chmod u+rwx file` (user/group/permissions); change group:

`chown user:group path` partitions: `fdisk -l` blk devices: `ls blk`

softlink link: in (fs) file link **LWN:** proper link; `pvcreate /dev/vda1`

create volume group: `vgcreate NAME1 /dev/vda1 /dev/vda2`

new volume: `lvcreate -L 1G -n NAME2 NAME1`

volume manipulation: `lvextend -resizefs -L 800M /dev/NAME1/NAME2`

Kernel

load/remove module: `is` module filename

Threads